
UNIVERSIDAD POLITÉCNICA DE VICTORIA

REPORTE DE PROTOCOLO DE INVESTIGACIÓN

DETECCIÓN DE PLAGAS EN CÍTRICOS UTILIZANDO APRENDIZAJE PROFUNDO Y
TINYML

QUE PRESENTA

ANIBAL GONZÁLEZ TOVAR

EN CUMPLIMIENTO DEL SEMINARIO 1, FORMALIZACIÓN E INICIO DEL PROYECTO
DE INVESTIGACIÓN COMO PARTE DE LA MAESTRÍA EN INGENIERÍA

ASESOR:

DR. YAHIR HERNÁNDEZ MIER

INSTITUCIONES RELACIONADAS

UNIVERSIDAD POLITÉCNICA DE VICTORIA

CIUDAD VICTORIA, TAMAULIPAS

11 AGOSTO 2025

1. PLANTEAMIENTO DEL PROBLEMA

1.1 Introducción

En la actualidad, la agricultura ha comenzado a beneficiarse de los avances en tecnologías digitales, especialmente aquellas vinculadas a la inteligencia artificial. Dentro de este contexto, se ha promovido el uso de sensores, drones y modelos de aprendizaje automático para mejorar la productividad y el manejo fitosanitario de los cultivos. En particular, los sistemas de monitoreo para la detección temprana de plagas y enfermedades se han desarrollado para reducir pérdidas, garantizar la calidad del producto y aumentar la eficiencia de las labores agrícolas. Sin embargo, la mayor parte de estas soluciones están diseñadas para funcionar en plataformas complejas que requieren conectividad constante o alto poder de cálculo, lo cual limita su adopción en zonas rurales o de bajos recursos.

A pesar de sus ventajas, las soluciones actuales presentan diversas limitaciones, como el alto costo de implementación, la dependencia de conexión a internet o la necesidad de personal capacitado para su operación. Estas barreras dificultan que los pequeños y medianos productores accedan a tecnologías inteligentes para el monitoreo fitosanitario. Además, la mayoría de los sistemas existentes no están optimizados para su uso en cultivos específicos como los cítricos, que representan un sector importante en muchas economías regionales. Las condiciones del campo, como variabilidad climática, falta de infraestructura tecnológica y diversidad biológica, exigen soluciones adaptadas, portátiles y de bajo consumo energético.

En respuesta a estas necesidades, se propone el desarrollo de un sistema de detección de plagas y enfermedades en cultivos de cítricos mediante el uso de TinyML. Esta tecnología permite la implementación de modelos de aprendizaje automático en dispositivos embebidos, capaces de realizar inferencias en tiempo real sin necesidad de conexión a la nube. A través de la captura y análisis de imágenes del follaje de los árboles, el sistema podrá identificar patrones característicos de infecciones o presencia de plagas, alertando al productor de manera oportuna. Con ello se busca brindar una solución accesible, eficiente y escalable que contribuya al manejo fitosanitario y a la sostenibilidad de la citricultura.

1.2 Objetivos

1.2.1 Objetivo general

Desarrollar un sistema de detección de plagas y enfermedades en cultivos de cítricos mediante el uso de TinyML, implementado en dispositivos embebidos que permitan la captura, procesamiento y análisis de imágenes en tiempo real, con el fin de brindar una herramienta accesible y eficiente para el manejo fitosanitario en entornos agrícolas.

1.2.2 Objetivos específicos

1. Identificar las plagas y enfermedades más comunes en cultivos de cítricos mediante revisión documental y consulta con expertos.
2. Capturar y etiquetar un conjunto de imágenes representativas de hojas de cítricos sanas y afectadas para el entrenamiento del modelo.
3. Diseñar y entrenar un modelo de clasificación basado en aprendizaje profundo, optimizado para implementarse en dispositivos de bajo recurso.

1.3 Justificación

La detección oportuna de plagas y enfermedades en cultivos es un aspecto fundamental en la agricultura, ya que impacta directamente en la calidad y cantidad de la producción, así como en la rentabilidad de los agricultores. Desde una perspectiva teórica, el presente trabajo se basa en el paradigma de la inteligencia artificial, en particular en el subcampo del aprendizaje automático, que ha demostrado ser eficaz para tareas de clasificación de imágenes y diagnóstico automatizado. El uso de TinyML, una tecnología emergente que permite la ejecución de modelos de aprendizaje automático en dispositivos embebidos de bajo consumo, representa una solución innovadora a los retos que enfrentan los productores rurales, al prescindir de conectividad constante y reducir el costo de implementación. Desde un enfoque práctico, este proyecto plantea el diseño de un sistema capaz de capturar imágenes en tiempo real desde el campo, analizarlas mediante un modelo optimizado de clasificación, e informar al agricultor sobre la presencia de afecciones en sus plantas. A nivel metódico, el trabajo contempla el levantamiento de un dataset propio, el entrenamiento y validación de un modelo ligero, y su despliegue en una plataforma embebida como el ESP32-CAM. Asimismo, se realizarán pruebas de campo para evaluar su desempeño bajo condiciones reales. El desarrollo de esta investigación beneficiará directamente a pequeños y medianos productores de cítricos, al proporcionarles una herramienta tecnológica accesible que contribuirá a mejorar el manejo fitosanitario, reducir pérdidas y aumentar la sostenibilidad de su actividad agrícola.

1.4 Hipótesis

1.4.1 Hipótesis 1:

El uso de modelos de TinyML implementados en dispositivos embebidos mejora la precisión en la detección de plagas en hojas de cítricos en comparación con la inspección visual manual.

1.4.2 Hipótesis 2:

La implementación de un sistema basado en TinyML reduce el tiempo de diagnóstico de enfermedades en cultivos de cítricos en al menos un 30% respecto a métodos tradicionales.

1.5 Alcance de la Investigación

Esta investigación abarca el diseño, desarrollo y validación de un sistema de detección de plagas y enfermedades en cítricos mediante TinyML, desde la recolección y etiquetado de imágenes hasta la implementación final en un dispositivo embebido Jetson Orin Nano.

El estudio se enfocará exclusivamente en afecciones que presenten síntomas visibles en frutos, las cuales serán capturadas con una cámara de alta resolución y procesadas mediante modelos de visión por computadora optimizados para ejecución en hardware de bajo consumo.

Las pruebas de rendimiento se realizan en campo, evaluando la precisión, velocidad de respuesta y viabilidad del sistema para su uso por productores de cítricos en zonas rurales.

No se contempla en esta fase la integración con sistemas de riego automatizado ni la cobertura de todas las variedades de cítricos, aunque se dejará abierta la posibilidad de ampliaciones futuras.

1.6 Viabilidad

La Universidad Politécnica de Victoria cuenta con diversos equipos de cómputo a disposición de los estudiantes, sin embargo, dichos equipos no son lo suficientemente potentes para la realización de entrenamientos de redes neuronales, pues se precisa de una gráfica y procesadores potentes ya que conlleva a cabo muchos procesos a la vez, por otro lado, la institución cuenta con doctores capacitados para la orientación de los alumnos en caso de tener alguna duda con el proyecto.

Recurso	Disponibilidad
Computadoras Thinkpad del laboratorio de cómputo.	La institución tiene a disposición del alumnado varios equipos de cómputo para su uso académico
Asesorías y orientación de parte de los doctores en la institución.	La universidad cuenta con doctores especializados en diversas ramas de la investigación.

Tabla 1. Recursos disponibles en la institución

Los entrenamientos usando redes convolucionales requieren de equipos de cómputo de alta gama, pues al utilizar tanto CPU como GPU, se requieren grandes capacidades de procesamiento de información para la realización de proyectos, los cuales no se encuentran a disposición en la institución, a continuación se plantean los recursos necesarios para la realización de entrenamientos:

Recurso	Disponibilidad
Computadora para experimentación con GPU potente marca NVIDIA (12 GB de VRAM o más)	El proceso de imágenes e información necesita de una gran cantidad de memoria virtual de la GPU para la realización de entrenamientos.

Tabla 2. Recursos necesarios y no disponibles en la institución

1.6.1 Solución a la falta de recursos

1. **Google Colab / Colab Pro:** Utilizar instancias con GPUs de hasta 12 GB (o superior en la versión Pro) para etapas críticas de entrenamiento.
2. **Adquisición personal:** Actualmente se cuenta con una computadora de gama alta para la realización de los entrenamientos la cual se obtuvo con recursos personales y se utiliza en la realización de proyectos.

2. MARCO TEÓRICO

2.1 Información general

La agricultura ha sido una de las actividades humanas más fundamentales para el desarrollo de la civilización, permitiendo la producción de alimentos y el sustento de millones de personas en todo el mundo. No obstante, los cultivos agrícolas enfrentan constantemente amenazas que ponen en riesgo su rendimiento, calidad y viabilidad económica. Entre estas amenazas, las plagas y enfermedades fúngicas, bacterianas o virales representan uno de los principales factores de pérdida en la producción agroalimentaria. La detección temprana y el monitoreo continuo de estas afectaciones es, por tanto, un aspecto crítico para la agricultura moderna.

En este sentido, la incorporación de tecnologías digitales en el ámbito agrícola ha dado paso a lo que se conoce como agricultura de precisión. Este enfoque integra sensores, sistemas de posicionamiento global, y herramientas de análisis de datos para mejorar la toma de decisiones y aumentar la productividad. Recientemente, la inteligencia artificial (IA) ha comenzado a desempeñar un papel protagónico en esta transformación. Dentro del amplio espectro de aplicaciones de IA, el aprendizaje automático (machine learning) ha sido especialmente útil para el análisis de imágenes, la predicción de rendimientos y la detección de anomalías.

Una de las ramas más prometedoras en esta área es TinyML, que consiste en la implementación de modelos de machine learning en dispositivos embebidos de baja potencia y recursos limitados. Esta tecnología permite ejecutar modelos de IA directamente en el lugar donde se generan los datos, sin necesidad de conexión constante a la nube, lo que reduce latencias, costos de transmisión de datos y consumo energético. TinyML resulta particularmente atractivo para aplicaciones agrícolas, ya que permite el despliegue de soluciones de monitoreo en campo, con dispositivos portátiles o instalados de manera permanente en invernaderos o parcelas.

2.1.2 Información específica

Numerosos estudios han abordado la aplicación de TinyML y otras tecnologías de inteligencia artificial en la agricultura. Rachana y col. (2023) utilizaron sensores espectrales Vis-NIR y modelos de redes neuronales ligeras para predecir la vida útil de frutas, alcanzando precisiones de hasta el 77.8% tras aplicar técnicas de cuantización. Este tipo de enfoques demuestra la viabilidad del procesamiento embebido para tareas de análisis de calidad alimentaria. Zervakis y col. (2022) trabajaron con redes neuronales convolucionales optimizadas para clasificar aceitunas por variedad y calidad utilizando microcontroladores, logrando más del 97% de precisión.

En el contexto de detección de plagas, Mancilla y col. (2023) desarrollaron una aplicación móvil basada en TensorFlow Lite capaz de identificar plagas en granos básicos con una eficacia del 95.8%, demostrando la eficacia de los modelos ligeros en clasificación visual.

Por otro lado, Morales y col. (2022) aplicaron metodologías ágiles para implementar una solución de reconocimiento de plagas mediante Google Teachable Machine en cultivos nicaragüenses, destacando la facilidad de uso de estas herramientas en contextos con poca infraestructura tecnológica.

A nivel de optimización de modelos, Rehman y col. (2023) exploraron el uso de arquitecturas como MobileViT y EfficientNet, aplicando técnicas de cuantización como PTQ y QAT. Los resultados indicaron que era posible reducir el tamaño de los modelos de 33 MB a menos de 10 MB, manteniendo una precisión del 77.8%. Este hallazgo es clave para la implementación de modelos en dispositivos edge con almacenamiento limitado. Complementando este enfoque, Sonmez y col. (2023) desarrollaron un sistema de particionamiento adaptativo entre el borde y la nube que permitió mejorar la eficiencia de inferencia en un 26.8% y reducir el consumo energético en 31.6%, lo que confirma la efectividad de las arquitecturas híbridas.

Por su parte, Suchithra y col. (2023) llevaron a cabo una revisión sobre sensores ópticos aplicados al fenotipo vegetal, mientras que Abuchar y col. (2019) destacaron la necesidad de mejorar la accesibilidad tecnológica en el uso de aprendizaje automático para el reconocimiento de enfermedades en plantas. Estas investigaciones subrayan tanto el potencial como los retos existentes en la adopción de tecnologías de IA en el sector agroindustrial.

A pesar de estos avances, la mayor parte de las aplicaciones revisadas se enfocan en cultivos distintos a los cítricos, lo que deja una brecha importante en cuanto a soluciones especializadas para estos cultivos. Además, gran parte de los desarrollos se ha probado en condiciones controladas o con datasets limitados, por lo que existe una clara necesidad de implementar y validar soluciones TinyML en escenarios reales de campo, especialmente orientadas a la detección de plagas de importancia económica en la citricultura.

2.2 Estado del Arte

La detección temprana de plagas en la agricultura mediante el uso de inteligencia artificial ha emergido como una solución eficaz frente a las pérdidas de producción. Con el avance de la tecnología, se ha hecho posible implementar modelos de aprendizaje automático en dispositivos embebidos, facilitando su aplicación en entornos rurales con recursos limitados. En este contexto, el presente proyecto se enfoca en la aplicación de TinyML en la detección de plagas en cultivos de cítricos, aprovechando su bajo consumo energético y capacidad de procesamiento en tiempo real.

Entre los trabajos relacionados, se encuentra el estudio de Rachana y col. (2023), quienes utilizaron sensores espectrales Vis-NIR junto a modelos ligeros para estimar la vida útil de frutas, logrando precisiones del 77.8% tras la cuantización. Este tipo de abordaje demuestra que los sensores no invasivos, combinados con modelos optimizados, pueden ofrecer soluciones viables para el monitoreo de calidad en productos agrícolas. De forma similar, Zervakis y col. (2022) desarrollaron una red neuronal convolucional optimizada para

clasificar aceitunas en tiempo real mediante microcontroladores, alcanzando una precisión superior al 97%. Este trabajo evidencia que es posible implementar sistemas de clasificación con alta exactitud en hardware con recursos limitados. Mancilla y col. (2023) aportaron con una aplicación móvil que integra TensorFlow Lite para detectar plagas en granos básicos, logrando una clasificación efectiva del 95.8% a partir de un conjunto limitado de datos, lo cual resalta el potencial del aprendizaje transferido y la eficiencia de los modelos ligeros en aplicaciones agrícolas.

Por otra parte, algunos estudios se enfocaron en revisiones técnicas y diagnósticos del estado actual. Suchithra y col. (2023) compararon el uso de sensores ópticos en fenotipado y agricultura de precisión, identificando brechas entre la teoría y su implementación en campo, así como la necesidad de adaptar estos sistemas a condiciones ambientales variables. En la misma línea, Abuchar y col. (2019) subrayan la falta de accesibilidad tecnológica como barrera para el uso de IA en agricultura, especialmente en regiones en desarrollo. Rehman y col. (2023) realizaron optimizaciones de modelos MobileViT y EfficientNet mediante técnicas como PTQ y QAT, disminuyendo el tamaño de los modelos sin afectar significativamente su precisión. Estos avances muestran el compromiso por parte de la comunidad científica con la miniaturización y eficiencia de modelos, fundamentales para su adopción en el campo.

Además, se han identificado estrategias para superar las limitaciones del edge computing. Sonmez y col. (2023) propusieron una arquitectura de partición de modelos entre el borde y la nube, lo que resultó en una reducción del consumo energético en 31.6% y una mejora en la eficiencia del 26.8%. Este tipo de enfoques híbridos permite distribuir la carga computacional según la disponibilidad de recursos, mejorando el rendimiento general del sistema. Morales y col. (2022), por su parte, desarrollaron una aplicación para el reconocimiento de plagas en cultivos centroamericanos utilizando metodologías ágiles y herramientas accesibles como Google Teachable Machine, evidenciando la viabilidad del desarrollo con recursos limitados y resaltando la importancia del diseño centrado en el usuario.

A pesar de los avances, se observa que la mayor parte de los estudios se centran en cultivos distintos a los cítricos, y muchos experimentos se realizan bajo condiciones controladas que no representan la realidad del campo. Asimismo, se ha explorado poco la integración robusta de sensores de bajo costo con procesamiento local eficiente y capacidades de aprendizaje adaptativo. Por lo tanto, existe una clara necesidad de desarrollar un sistema basado en TinyML para la detección de plagas en cítricos en entornos reales de producción, que permita el monitoreo continuo, el procesamiento en tiempo real y la toma de decisiones autónoma. Esta necesidad justifica la realización del presente trabajo como aporte tecnológico y científico al sector agroindustrial.

3. METODOLOGÍA

3.1 Material, equipo y herramientas

Para el desarrollo del proyecto se utilizará una computadora de escritorio de alto rendimiento equipada con una tarjeta gráfica NVIDIA RTX 5070, la cual permite acelerar el proceso de entrenamiento de modelos de aprendizaje profundo mediante procesamiento paralelo. Esta estación de trabajo también cuenta con un procesador AMD Ryzen 7 7700 de 8 núcleos, que brinda un rendimiento óptimo para la ejecución de tareas pesadas como el preprocesamiento de imágenes, configuración de entornos virtuales y compilación de modelos. Se utilizará una cámara Sony de 38 megapíxeles para la captura de imágenes de alta resolución de hojas de cítricos sanas y enfermas, lo que asegurará la calidad de los datos para el entrenamiento. Para la etapa de despliegue del modelo, se emplea un dispositivo embebido Jetson Orin Nano, ideal para correr inferencias de modelos de deep learning en campo, gracias a su arquitectura optimizada para IA y bajo consumo de energía. El software Docker será utilizado para contenerizar los entornos de desarrollo, lo que permitirá reproducibilidad, portabilidad y facilidad de despliegue tanto en la estación de trabajo como en el dispositivo embebido.

3.2 Primera etapa: Identificación de plagas y enfermedades (Objetivo específico 1)

En esta etapa se realizará una revisión documental de fuentes científicas confiables como revistas indexadas, libros y repositorios agrícolas especializados, con el fin de identificar las plagas y enfermedades más comunes que afectan a los cultivos de cítricos. Además, se complementará la información mediante entrevistas a productores locales y consulta con especialistas en fitosanidad. Se creará una lista priorizada de afecciones que presenten signos visibles en hojas y frutos, para asegurar que sean detectables mediante visión por computadora.

3.3 Segunda etapa: Captura y etiquetado de imágenes (Objetivo específico 2)

Utilizando la cámara Sony de 38 MP, se capturarán imágenes de hojas sanas y enfermas en diferentes condiciones de luz, ángulos y estadios de desarrollo. Las imágenes se almacenarán en carpetas clasificadas por tipo de afección y se aplicarán técnicas de aumento de datos (data augmentation) como rotación, cambio de brillo y volteo horizontal. Posteriormente, las imágenes serán etiquetadas utilizando herramientas como Labelling o Robo Flow, asignando clases específicas a cada afección visible. Este conjunto de datos servirá como base para entrenar el modelo de clasificación.

3.4 Tercera etapa: Entrenamiento y optimización del modelo (Objetivo específico 3)

Con el conjunto de datos preparado, se diseñará un modelo de clasificación basado en arquitecturas livianas como MobileNetV2 o EfficientNet. El entrenamiento se realizará en la computadora de escritorio utilizando TensorFlow o PyTorch, aprovechando la aceleración por GPU proporcionada por la tarjeta NVIDIA RTX 5070. Se utilizará Docker para crear un entorno aislado con todas las dependencias necesarias. Una vez entrenado, el modelo será convertido a TensorFlow Lite y se aplicarán técnicas de cuantización post-entrenamiento

para reducir su tamaño. Finalmente, el modelo será cargado y probado en el Jetson Orin Nano para validar su rendimiento en tiempo real.

4. CRONOGRAMA DE ACTIVIDADES

[illegible]

Bibliografía

1. Alhassan, J. K., et al. (2023). **TinyML for Plant Disease Detection: Efficient Edge AI Solutions for Apple and Mango Leaves.** *Sensors*.
2. Picon, A., et al. (2023). **Automatic and Reliable Leaf Disease Detection Using Deep Learning Techniques.** *Agriengineering*.
Chávez-Aragón, G., et al. (2023). **TinyML Olive Fruit Variety Classification by Means of Convolutional Neural Networks on IoT Edge Devices.** *Agriengineering*.
3. Mendoza, L., et al. (2019). **Machine Learning en la detección de enfermedades en plantas.** *Revista Iberoamericana de Tecnología Postcosecha*.
4. Al-Mahmood, A., et al. (2023). **TinyML-Sensor for Shelf Life Estimation of Fresh Date Fruits.** *Sensors*.
5. Mahlein, A.-K., et al. (2023). **Plant Disease Detection by Imaging Sensors – Parallels and Specific Demands for Precision Agriculture and Plant Phenotyping.** *Sensors*.
6. Castillo, J., et al. (2023). **Inteligencia Artificial: Machine Learning para Detección Temprana de Plagas y Enfermedades de Cultivos Básicos, Nicaragua.** *Revista Científica Multidisciplinaria*.
7. Singh, V., et al. (2023). **Edge-Optimized Deep Learning Architectures for Classification of Agricultural Insects with Mobile Deployment.** *Sensors*.
8. Pérez, R., et al. (2023). **Optimizing Lightweight Recurrent Networks for Solar Forecasting in TinyML: Modified Metaheuristics and Legal Implications.** *Sensors*.
9. Martínez, H., et al. (2023). **Detección de pimiento morrón utilizando TinyML.** *Agriengineering*.

5. SECCIÓN DE FIRMAS DEL COMITÉ DE SEGUIMIENTO

Anibal Gonzalez Tovar

Dr. Juan López Hernández

Dr. José Amparo Rodríguez García

Dr. Said Polanco Martagón
