

DETECCION DE PLAGAS EN CITRICOS A TRAVES DE DISPOSITIVOS EMBEBIDOS UTILIZANDO TINYML

T E S I S
QUE PARA OBTENER EL GRADO DE
MAESTRO EN INGENIERÍA
P R E S E N T A

ANIBAL GONZÁLEZ TOVAR

DIRECTOR DE TESIS:
DR. MARCO AURELIO NUÑO MAGANDA

CO-DIRECTOR DE TESIS:
DR. YAHIR HERNÁNDEZ MIER

La tesis presentada por ANIBAL GONZÁLEZ TOVAR fue aprobada por:

DR. MARCO AURELIO NUÑO MAGANDA, Director

DR. YAHIR HERNÁNDEZ MIER, Co-Director

Cd. Victoria, Tamaulipas, México, 21 de Mayo de 2025

**DETECCION DE PLAGAS EN CITRICOS A TRAVES DE
DISPOSITIVOS EMBEBIDOS UTILIZANDO TINYML**

ANIBAL GONZÁLEZ TOVAR, 2025

Abstract

PEST DETECTION IN CITRUS TREES THROUGH EMBEDDED DEVICES USING TINYML

ANIBAL GONZÁLEZ TOVAR, 2025

Agradecimientos

Índice General

Resumen	III
Abstract	VI
Nomenclatura	XVI
1. Introducción	1
1.1. Motivación	2
1.2. Planteamiento del problema	2
1.3. Objetivos	3
1.3.1. Objetivo general	3
1.3.2. Objetivos específicos	3
1.4. Justificación	3
1.5. Diseño de investigación	3
1.5.1. Pregunta de investigación	4
1.5.2. Hipótesis	4
2. Marco Teórico	5
2.1. Cítricos y su importancia en México y Tamaulipas	5
2.2. Importancia de la detección temprana	7
2.3. Aplicación de visión por computadora en la detección de plagas y enfermedades .	7
2.4. Computación en el Borde: Implementación de Modelos de Aprendizaje Profundo en Dispositivos Embebidos	7
2.5. Jetson Nano Orin como plataforma para la implementación	8
2.6. Estado del Arte: Detección de Plagas y Enfermedades en Frutos de Naranja mediante Aprendizaje Profundo	8
2.6.1. Aplicaciones de CNN en la Detección de Plagas en Frutos	8
2.6.2. Integración de Aprendizaje Profundo y Edge Computing	9
2.6.3. Conjuntos de Datos y Transferencia de Aprendizaje	9
2.6.4. Técnicas de Atención y Aprendizaje Débilmente Supervisado	9

Índice de Figuras

2.1. Plagas en citricos en la región de Tamaulipas.	6
2.2. Enfermedades que afectan a los citricos en la región de Tamaulipas.	6

Índice de Tablas

Nomenclatura

ACHPA	Automatically Controlled Hydro-Ponic Agriculture
ANFIS	Adaptive Neuro-Fuzzy Inference System
BGR	Blue Green Red
CE	Conductividad Eléctrica
DFT	Deep Flow Technique
DRFT	Dynamic Root Floating Technique
HSV	Hue Saturation Value
Hp	Horsepower
IoT	Internet of Things
MicroSD	Micro tarjeta de memoria Secure Digital
MQTT	Message Queuing Telemetry Transport
NFT	Nutrient Film Technique
OD	Oxígeno Disuelto
pH	Potencial de Hidrógeno
PIB	Producto Interior Bruto
Pi OS	Sistema Operativo recomendado para la computadora Raspberry Pi
PLC	Programmable Logic Controller
PVC	Polyvinyl Chloride
PMW	Pulse Width Modulation
USB	Universal Serial Bus

1

Introducción

La citricultura es una de las actividades agrícolas más relevantes en México, y el estado de Tamaulipas no es la excepción. Sin embargo, la producción de cítricos enfrenta desafíos significativos debido a la incidencia de diversas plagas y enfermedades que afectan la calidad y cantidad de la cosecha. Entre las plagas más perjudiciales se encuentran el psílido asiático de los cítricos (*Diaphorina citri*), vector del Huanglongbing (HLB), el pulgón café (*Toxoptera citricida*), el minador de la hoja (*Phyllocnistis citrella*) y el ácaro rojo (*Panonychus citri*) [1], [2]. La detección temprana y el monitoreo constante son esenciales para el manejo efectivo de estas plagas. En este contexto, la aplicación de técnicas de aprendizaje automático (Machine Learning) en dispositivos de bajo consumo energético, conocidos como TinyML, ofrece una solución innovadora y eficiente [3]. Dispositivos como la Jetson Nano Orin permiten la implementación de modelos de detección en tiempo real directamente en el campo, facilitando la toma de decisiones rápidas y precisas sin la necesidad de conexión constante a la nube.

1. Introducción

SEPTIEMBRE 2025 - AGOSTO 2026												
ACTIVIDAD	SEP	OCT	NOV	DIC	ENE	FEB	MAR	ABR	MAY	JUN	JUL	AGO
Revisión Bibliográfica												
Identificar las plagas y enfermedades más comunes en cultivos de cítricos mediante revisión documental y consulta con expertos (Objetivo específico 1)												
Capturar y etiquetar un conjunto de imágenes representativas de hojas de cítricos sanas y afectadas para el entrenamiento del modelo (Objetivo específico 2)												
Análisis de Resultados												
Diseñar y entrenar un modelo de clasificación basado en aprendizaje profundo, optimizado para implementarse en dispositivos de bajo recurso (Objetivo específico 3)												
Análisis de Resultados												
Resultados en Congresos												
Escritura de tesis												
Examen TOEFL												
Examen de Grado												

1.1 Motivación

La creciente amenaza de plagas en los cultivos de cítricos y las limitaciones de los métodos tradicionales de detección impulsan la necesidad de soluciones tecnológicas avanzadas. La integración de TinyML en dispositivos como la Jetson Nano Orin permite desarrollar sistemas de monitoreo autónomos, asequibles y eficientes, adaptados a las condiciones específicas de las regiones productoras como Tamaulipas[4].

1.2 Planteamiento del problema

La falta de sistemas de detección temprana y monitoreo continuo de plagas en los cultivos de cítricos en Tamaulipas contribuye a la propagación de enfermedades y a la disminución de la productividad. Los métodos convencionales son costosos, requieren mano de obra especializada y no siempre ofrecen resultados en tiempo real. Es necesario desarrollar una solución que permita la detección automática y oportuna de plagas utilizando tecnologías accesibles y de bajo consumo energético.

1.3 Objetivos

1.3.1 Objetivo general

Desarrollar e implementar un sistema basado en TinyML para la detección automática de plagas en cultivos de cítricos en el estado de Tamaulipas, utilizando dispositivos de bajo consumo energético como la Jetson Nano Orin.

1.3.2 Objetivos específicos

1. Identificar las principales plagas que afectan los cultivos de cítricos en Tamaulipas.
2. Recolectar y procesar datos visuales de las plagas para el entrenamiento del modelo de Machine Learning.
3. Diseñar y entrenar un modelo de detección de plagas optimizado para dispositivos de recursos limitados.
4. Implementar el modelo en una Jetson Nano Orin y evaluar su desempeño en condiciones de campo.

1.4 Justificación

La implementación de un sistema de detección de plagas basado en TinyML en dispositivos como la Jetson Nano Orin ofrece múltiples beneficios:

- Eficiencia: Permite la detección en tiempo real sin necesidad de conexión a internet.
- Accesibilidad: Utiliza hardware de bajo costo, facilitando su adopción por pequeños y medianos productores.
- Sostenibilidad: Reduce el uso indiscriminado de pesticidas al permitir intervenciones más precisas.

1.5 Diseño de investigación

La investigación se llevará a cabo en las siguientes etapas:

- Revisión Bibliográfica: Estudio de las plagas más comunes en los cítricos de Tamaulipas y de las técnicas actuales de detección.
- Recolección de Datos: Captura de imágenes de las plagas en condiciones reales de cultivo.

1. Introducción

- Desarrollo del Modelo: Entrenamiento de un modelo de Machine Learning optimizado para dispositivos de bajo consumo.
- Implementación y Pruebas: Despliegue del modelo en una Jetson Nano Orin y evaluación de su desempeño en campo.

1.5.1 Pregunta de investigación

- ¿Cuáles son las plagas más prevalentes en los cultivos de cítricos en Tamaulipas?
- ¿Qué características visuales permiten la identificación precisa de estas plagas?
- ¿Qué tan efectivo es un modelo de TinyML implementado en una Jetson Nano Orin para la detección de plagas en condiciones de campo?

1.5.2 Hipótesis

- La implementación de un sistema de detección de plagas basado en TinyML en una Jetson Nano Orin permitirá identificar de manera precisa y en tiempo real las principales plagas que afectan los cultivos de cítricos en Tamaulipas, mejorando la eficiencia en el manejo fitosanitario y reduciendo las pérdidas económicas asociadas.

2

Marco Teórico

La presente investigación se fundamenta en diversos conceptos y tecnologías que convergen para dar solución al problema de detección temprana de plagas en cultivos de cítricos. A través de este marco teórico se revisan los principales antecedentes y bases científicas relacionadas con la importancia de la citricultura en México, los impactos de las plagas en regiones específicas como Tamaulipas, y las soluciones tecnológicas emergentes que han demostrado ser efectivas en el contexto agrícola. Asimismo, se describen los principios del aprendizaje automático, su aplicación en dispositivos de recursos limitados bajo el paradigma de TinyML, y el papel que juega el microcontrolador JetsonNano Orin como plataforma de despliegue. Esta revisión permite entender los fundamentos necesarios para el desarrollo e implementación del sistema propuesto [5].

2.1 Cítricos y su importancia en México y Tamaulipas

Los cítricos, especialmente el limón y la naranja, representan cultivos estratégicos para el sector agrícola mexicano. En el estado de Tamaulipas, municipios como Llera, Güémez y Padilla concentran gran parte de la producción citrícola. Esta actividad no solo genera empleo rural, sino que también constituye una fuente importante de ingresos para miles de familias productoras [1].

Sin embargo, la citricultura se ve afectada cada vez más por plagas como:

1. Plagas que afectan directamente al fruto de la naranja

- Mosca de la fruta (*Ceratitis capitata*): La hembra deposita sus huevos en la pulpa del fruto, y las larvas resultantes se alimentan de esta, causando la descomposición del fruto y su caída prematura [6].
- Ácaro rojo de los cítricos (*Panonychus citri*): Se alimenta de la superficie del fruto, causando decoloraciones y manchas que reducen su valor comercial.

2. Marco Teórico



- Trips (*Scirtothrips dorsalis*): Estos insectos raspan la superficie del fruto para alimentarse, dejando cicatrices y manchas plateadas que afectan la apariencia del fruto.

2. Enfermedades que afectan directamente al fruto de la naranja

- Leprosis de los cítricos: Causada por el Citrus leprosis virus, esta enfermedad provoca lesiones necróticas en el fruto, afectando su apariencia y calidad.
- Pudrición del fruto: Enfermedad fúngica que causa la descomposición del fruto, especialmente en condiciones de alta humedad, afectando su integridad y sabor [7].



(a) acaro rojo



(c) mosca de la fruta

Figura 2.1. Plagas en cítricos en la región de Tamaulipas.





Figura 2.2. Enfermedades que afectan a los cítricos en la región de Tamaulipas.

2.2 Importancia de la detección temprana

La detección temprana de estas plagas y enfermedades es crucial para implementar medidas de control efectivas y minimizar las pérdidas económicas. La identificación visual de síntomas en el fruto permite una respuesta rápida y dirigida, evitando la propagación de las afecciones y preservando la calidad de la cosecha [2].

2.3 Aplicación de visión por computadora en la detección de plagas y enfermedades

El aprendizaje automático (Machine Learning, ML) ha demostrado ser una herramienta poderosa en la agricultura de precisión, especialmente en la detección temprana de plagas y enfermedades que afectan directamente a los frutos de cítricos como la naranja. Las técnicas de ML permiten analizar grandes volúmenes de datos e identificar patrones complejos que pueden ser indicativos de la presencia de agentes patógenos o infestaciones.

En particular, las redes neuronales convolucionales (CNN) han sido ampliamente utilizadas para la clasificación de imágenes de frutos afectados. Por ejemplo, un estudio evaluó la eficacia de modelos como ResNet-50, GoogleNet, VGG-16 y AlexNet en la clasificación de naranjas sanas y afectadas por la mosca mediterránea de la fruta (*Ceratitis capitata*), logrando precisiones superiores al 98 % en etapas tempranas de infestación.

Además, se han desarrollado sistemas de diagnóstico basados en CNN que combinan módulos como Inception con EfficientNetV2 para mejorar la extracción de características multiescala, alcanzando precisiones de reconocimiento superiores al 95 % en la identificación de enfermedades como el cancro y la leprosis en frutos de naranja[4].

2.4 Computación en el Borde: Implementación de Modelos de Aprendizaje Profundo en Dispositivos Embebidos

La computación en el borde (Edge Computing) permite procesar datos localmente en dispositivos embebidos, reduciendo la latencia y la dependencia de conexiones a la nube. Esto es especialmente útil en entornos agrícolas donde la conectividad puede ser limitada.

La Jetson Nano Orin de NVIDIA es una plataforma de computación de alto rendimiento diseñada para aplicaciones de inteligencia artificial en el borde. Su capacidad para procesar modelos complejos de aprendizaje profundo en tiempo real la convierte en una herramienta ideal para la detección de plagas y enfermedades en frutos de naranja directamente en el campo.

2. Marco Teórico

Un estudio presentó un sistema inteligente de detección de enfermedades en frutos cítricos utilizando una combinación de CNN y LSTM, optimizado para dispositivos con recursos limitados. Este sistema logró una alta precisión en la clasificación de enfermedades como la pudrición del fruto y la melanosis, demostrando su viabilidad para aplicaciones en entornos agrícolas reales. Además, se han explorado técnicas de atención y aprendizaje débilmente supervisado para mejorar la clasificación de plagas en frutos cítricos, permitiendo la identificación de regiones relevantes en las imágenes sin necesidad de anotaciones detalladas[3].

2.5 Jetson Nano Orin como plataforma para la implementación

La Jetson Nano Orin de NVIDIA es una plataforma de computación de alto rendimiento diseñada para aplicaciones de inteligencia artificial en el borde. Su capacidad para procesar modelos complejos de aprendizaje profundo en tiempo real la convierte en una herramienta ideal para la detección de plagas y enfermedades en frutos de naranja directamente en el campo, sin necesidad de conexión a la nube[8].

2.6 Estado del Arte: Detección de Plagas y Enfermedades en Frutos de Naranja mediante Aprendizaje Profundo

La aplicación de técnicas de aprendizaje profundo, especialmente las redes neuronales convolucionales (CNN), ha revolucionado la detección y clasificación de plagas y enfermedades en frutos cítricos. Estas metodologías permiten identificar patrones complejos en imágenes, facilitando la detección temprana y precisa de anomalías en los frutos, lo cual es esencial para implementar medidas de control eficaces y minimizar pérdidas económicas.

2.6.1 Aplicaciones de CNN en la Detección de Plagas en Frutos

Diversos estudios han demostrado la eficacia de las CNN en la identificación de plagas que afectan directamente al fruto de la naranja. Por ejemplo, en un estudio reciente, se evaluaron cuatro modelos preentrenados de CNN (ResNet-50, GoogleNet, VGG-16 y AlexNet) para clasificar imágenes de naranjas sanas y afectadas por la mosca mediterránea de la fruta (*Ceratitis capitata*). Los resultados mostraron que el modelo VGG-16, optimizado con el algoritmo SGDM, alcanzó una precisión del 98.33 % en la etapa inicial de infestación, mientras que AlexNet logró una precisión del 99.33 % en etapas posteriores de la infestación[9].

Además, se ha propuesto un sistema de diagnóstico basado en CNN para detectar enfermedades en frutos cítricos, combinando el módulo Inception con EfficientNetV2 para mejorar la extracción

2.6. Estado del Arte: Detección de Plagas y Enfermedades en Frutos de Naranja mediante Aprendizaje Profundo

de características multiescala. Este enfoque logró una precisión de reconocimiento superior al 95 % en la identificación de enfermedades como el cancro y la leprosis en frutos de naranja.

2.6.2 Integración de Aprendizaje Profundo y Edge Computing

La implementación de modelos de aprendizaje profundo en dispositivos de cómputo en el borde (edge computing), como la Jetson Nano Orin, permite realizar detecciones en tiempo real directamente en el campo. Un estudio presentó un sistema inteligente de detección de enfermedades en frutos cítricos utilizando una combinación de CNN y LSTM, optimizado para dispositivos con recursos limitados. Este sistema logró una alta precisión en la clasificación de enfermedades como la pudrición del fruto y la melanosis, demostrando su viabilidad para aplicaciones en entornos agrícolas reales .

2.6.3 Conjuntos de Datos y Transferencia de Aprendizaje

La disponibilidad de conjuntos de datos de alta calidad es crucial para entrenar modelos de aprendizaje profundo efectivos. Se ha desarrollado un conjunto de datos denominado CitDet, que contiene más de 32,000 anotaciones de frutos cítricos, incluyendo imágenes de naranjas afectadas por enfermedades como el Huanglongbing (HLB). Este conjunto de datos ha sido utilizado para entrenar y evaluar modelos de detección de objetos, mejorando la precisión en la identificación de frutos enfermos en entornos de huerto[10].

Asimismo, la transferencia de aprendizaje ha sido empleada para mejorar el rendimiento de los modelos en la detección de enfermedades en frutos cítricos. Utilizando modelos preentrenados como EfficientNetB3 y ResNet50, se ha logrado una precisión de hasta el 99.58 % en la clasificación de enfermedades en naranjas, incluso con conjuntos de datos limitados.

2.6.4 Técnicas de Atención y Aprendizaje Débilmente Supervisado

Para abordar los desafíos asociados con la anotación manual de datos, se han explorado técnicas de atención y aprendizaje débilmente supervisado. Un enfoque basado en mapas de activación de atención ha sido propuesto para mejorar la clasificación de plagas en frutos cítricos, permitiendo la identificación de regiones relevantes en las imágenes sin necesidad de anotaciones detalladas. Este método ha demostrado ser eficaz en la detección de plagas como el ácaro rojo y el trips en naranjas.

En resumen, los avances en el aprendizaje profundo han facilitado el desarrollo de sistemas precisos y eficientes para la detección de plagas y enfermedades que afectan directamente al fruto de la naranja. La integración de estas tecnologías en dispositivos de cómputo en el borde, como la Jetson Nano Orin, permite su aplicación práctica en entornos agrícolas, ofreciendo una herramienta poderosa para mejorar la salud de los cultivos y reducir las pérdidas económicas asociadas.

2. Marco Teórico

Diagrama de Gantt - Proyecto: Uso de TinyML para la detección de plagas y enfermedades en cítricos

Cuatrimestre 2 (Enero - Abril 2025)

Captura de imágenes	Captura de imágenes de naranjas			
	January	February	March	April

Cuatrimestre 3 (Mayo - Agosto 2025)

Segmentación y etiquetado	Segmentación y Etiquetado			
	May	June	July	August

Cuatrimestre 4 (Septiembre - Diciembre 2025)

Captura de más imágenes	Captura extra y pruebas de modelos			
	September	October	November	December
Pruebas de modelos de ML				

2.6. Estado del Arte: Detección de Plagas y Enfermedades en Frutos de Naranja
mediante Aprendizaje Profundo

Cuatrimestre 5 (Enero - Abril 2026)

Verificación de modelos entrenados	Verificación de resultados de entrenamiento			
	January	February	March	April

Bibliografía

- [1] SENASICA, Manual Operativo para la Atención de Plagas de los Cítricos, Consultado el 21 de mayo de 2025, 2021. dirección: https://www.gob.mx/cms/uploads/attachment/file/614759/Manual_operativo_Plagas_de_los_C_tricos.pdf.
- [2] S. de Agricultura y Desarrollo Rural, Plagas y enfermedades comunes del limón, Consultado el 21 de mayo de 2025, 2020. dirección: <https://www.gob.mx/agricultura/articulos/plagas-y-enfermedades-comunes-del-limon>.
- [3] E. Arduino, Running TinyML on the ESP32 with TensorFlow Lite Micro, Consultado el 21 de mayo de 2025, 2023. dirección: <https://eloquentarduino.com/posts/tensorflow-lite-tinyml-esp32>.
- [4] W. Gómez-Flores, J. J. Garza-Saldaña y S. E. Varela-Fuentes, «CitrusUAT: A dataset of orange Citrus sinensis leaves for abnormality detection using image analysis techniques,» Data in Brief, vol. 52, pág. 109 908, 2024, ISSN: 2352-3409. DOI: <https://doi.org/10.1016/j.dib.2023.109908>. dirección: <https://www.sciencedirect.com/science/article/pii/S2352340923009514>.
- [5] Y. Guo, L. Xie y M. Zhang, «Attention-Based Weakly Supervised Learning for Citrus Pest Classification Using Visual Explanation Maps,» arXiv preprint, 2021. arXiv: [2110.00881](https://arxiv.org/abs/2110.00881) [cs.CV]. dirección: <https://arxiv.org/abs/2110.00881>.
- [6] S. Hassan, A. Malik y H. Kim, «Early and Late Infestation Stage Detection of Mediterranean Fruit Fly Using Transfer Learning-Based Deep CNN Models,» Computers in Biology and Medicine, vol. 156, pág. 106 728, 2023. DOI: [10.1016/j.combiomed.2023.106728](https://doi.org/10.1016/j.combiomed.2023.106728). dirección: <https://doi.org/10.1016/j.combiomed.2023.106728>.
- [7] X. Zhang, L. Li y Q. Zhao, «Multi-scale Citrus Disease Recognition Based on Inception and EfficientNetV2,» Frontiers in Genetics, vol. 14, pág. 1 253 934, 2023. DOI: [10.3389/fgene.2023.1253934](https://doi.org/10.3389/fgene.2023.1253934). dirección: <https://www.frontiersin.org/articles/10.3389/fgene.2023.1253934/full>.
- [8] J. Li, F. Wang y Z. Tang, «An Edge-Based Smart Detection System for Citrus Fruit Diseases Using CNN and LSTM,» Sustainability, vol. 15, n.º 5, pág. 4576, 2023. DOI: [10.3390/su15054576](https://doi.org/10.3390/su15054576). dirección: <https://www.mdpi.com/2071-1050/15/5/4576>.
- [9] M. Iqbal, S. Ullah, T. Ahmad et al., «Deep Transfer Learning-Based Detection and Classification of Citrus Plant Diseases,» International Journal of Advanced Computer Science and Applications (IJACSA), vol. 14, n.º 5, págs. 221-230, 2023. DOI: [10.14569/IJACSA.2023.0140526](https://doi.org/10.14569/IJACSA.2023.0140526). dirección: <https://dx.doi.org/10.14569/IJACSA.2023.0140526>.

BIBLIOGRAFÍA

- [10] X. Chen, X. Sun y D. Wang, «CitDet: A Dataset for Citrus Fruit Detection in Orchard Environments,» arXiv preprint, 2023. arXiv: [2309.05645](https://arxiv.org/abs/2309.05645) [cs.CV]. dirección: <https://arxiv.org/abs/2309.05645>.